



Modelo de IA Personalizado com RAG

Projeto Integrador 6



Documentos da EGA Soluções Industriais



Ollama


- É uma ferramenta de código aberto que executa LLMs (*Large Language Models*)
- Permite executar de forma muito fácil modelos localmente, via CLI, GUI ou APIs
- É multiplataforma, podendo operar sem internet, garantindo privacidade de dados e eliminando custos com APIs de nuvem
- <https://ollama.com/>

Alguns modelos

(dentre os milhares)

- Gemma – Google
- Phi – Microsoft
- Llama – Meta
- DeepSeek – DeepSeek
- Mistral – Mistral AI
- Qwen – Alibaba

- Features: Cloud, Embedding, Vision, Tools, Thinking



```
Ubuntu-24.04 x + v
seiiti@seiiti: $ docker exec -it projeto_integrador_6-ollama-1 bash
root@234226e1dbe1:/# ollama run gemma3:1b
>>> por que o céu é azul?
O céu é azul por causa de um fenômeno chamado **dispersão de Rayleigh**. Essa é a explicação mais simples e confiável para isso. Vamos entender melhor:

**1. A Luz do Sol:** A luz do sol que entra na Terra é, na verdade, composta por todas as cores do arco-íris.

**2. A Atmosfera:** A atmosfera terrestre é composta por gases como nitrogênio e oxigênio.

**3. A Dispersão de Rayleigh:** Quando a luz do sol entra na atmosfera, ela colide com as partículas de gás. A dispersão de Rayleigh é o fenômeno que faz com que a luz seja espalhada em diferentes direções. O que acontece é que a luz azul tem um comprimento de onda menor e, portanto, é espalhada com mais facilidade do que as outras cores.

**4. Por que vemos o azul no céu?** Como a luz azul é mais espalhada, ela se dispersa em todas as direções, fazendo com que o que vemos do céu é a cor azulada.

**Analogia:** Imagine que você joga uma bolinha de tênis em uma sala com muitos obstáculos. A bolinha de tênis (a luz) vai "pular" em todas as direções, e você verá a cor da bolinha em diferentes pontos da sala.

**Por que o sol se põe vermelho?** À medida que o sol se põe, a luz do sol precisa atravessar uma camada maior de atmosfera. A luz azul é mais dispersa, então a maior parte da luz que chega aos nossos olhos é da cor vermelha e amarela.

**Em resumo:** O céu é azul porque a luz azul do sol é espalhada pela atmosfera, fazendo com que ela se disperse em todas as direções, e nós vemos essa dispersão.

**Você tem mais alguma pergunta sobre o céu ou sobre o universo?**

>>>  Send a message (/? for help)
```

Teste

- Execução do modelo Gemma 3:1B perguntando "Por que o céu é azul?"
- A resposta inicia-se em menos de 1 segundo

Resultado de testes de alguns modelos no ajuste de prompts

modelo	tamanho	parâmetro	tempo	comprimento	opnião
gemma2:2b	1.52GB	2.6B	15	797	inglês
gemma3:1b	0.76GB	999.89M	41	586	inglês
gemma3:4b	3.11GB	4.3B	171	868	ok
phi3.5:3.8b	2.03GB	3.8B	543	5738	alucinou
phi4-mini:3.8b	2.32GB	3.8B	234	1469	ótimo
qwen3:0.6b	0.49GB	751.63M	98	481	ok
qwen3:1.7b	1.27GB	2.0B	158	961	médio
qwen3:4b	2.33GB	4.0B	511	1410	bom
qwen3.5:2b	2.55GB	2.3B	515	626	ok
qwen3.5:4b	3.16GB	4.7B	1320	1059	ok
llama3:8b	4.34GB	8.0B	486	794	ok
llama3.2:3b	1.88GB	3.2B			
mistral:7b	4.07GB	7.2B	509	1767	inglês
llm2.5-thinking:1.2b	0.68GB	1.2B	69	611	inglês
gemma3:270m	0.27GB	268.10M	25	244	ruim
llama2:7b	3.56GB	7B	563	1600	inglês




modelo	tamanho	parâmetro	tempo	comprimento	opnião
gemma2:2b	1.52GB	2.6B	307	929	ok
gemma3:1b	0.76GB	999.89M	347	651	simples
gemma3:4b	3.11GB	4.3B	988	1176	bom
phi3.5:3.8b	2.03GB	3.8B	1199	1104	bom
phi4-mini:3.8b	2.32GB	3.8B	674	2436	ótimo 4p
qwen3:0.6b	0.49GB	751.63M	498	572	simples
qwen3:1.7b	1.27GB	2.0B	1018	715	simples
qwen3:4b	2.33GB	4.0B	859	1019	bom
qwen3.5:2b	2.55GB	2.3B	1385	1516	bom
qwen3.5:4b	3.16GB	4.7B	1380	1117	bom
llama3:8b	4.34GB	8.0B	1041	780	ok
llama3.2:3b	1.88GB	3.2B	470	1219	bom
mistral:7b	4.07GB	7.2B	1060	1969	bom estruturado
llm2.5-thinking:1.2b	0.68GB	1.2B	287	557	simples think
gemma3:270m	0.27GB	268.10M	32	1855	inglês
llama2:7b	3.56GB	7B	1233	2137	inglês

RAG e Embedding

- RAG (Retrieval-Augmented Generation) e *Embedding* permite que você consulte seus próprios documentos de forma privada e precisa.
- Convertendo seus textos em vetores numéricos e utilizando um modelo de linguagem para responder perguntas com base nesse contexto.






Carga Inicial



Modelos de IA

Recuperação



Banco de dados vetorial





EmbeddingGemma-300m
Google's new efficient embedding model

EmbeddingGemma

- Desenvolvido pelo Google DeepMind
- Treinado para converter texto em representações numéricas
- Capturam o significado semântico
- Leve e código aberto
- Projetado para dispositivos locais


MTEB (Multilingual, v2)

Model*	Size	Mean (Task)	Retrieval	Classification	Clustering
EmbeddingGemma	308M	61.15	62.49	60.90	51.17
granite-embedding-278m-multilingual	278M	53.74	52.20	54.09	41.41
gte-multilingual-base	305M	58.24	56.50	57.17	44.33
multilingual-e5-large	560M	58.55	54.08	59.43	41.70
bge-m3	568M	59.56	54.60	60.35	40.88
jina-embeddings-v3	572M	58.37	55.76	58.77	45.65
Qwen-Embedding-0.6B	595M	64.34	64.65	66.83	52.33

*GENERAL-PURPOSE OPEN EMBEDDING MODELS

ChromaDB

- Banco de dados vetorial de código aberto
- Projetado para armazenar, gerenciar e recuperar *embeddings* de vetore
- Amplamente utilizado em aplicações de Inteligência Artificial (IA) generativa
- Foco em busca semântica e RAG




Outros bancos de dados vetoriais

- **Pinecone**: facilidade de uso e escalabilidade em nuvem
- **Milvus**: grandes conjuntos de dados
- **Qdrant**: escrito em Rust, alta performance e recursos avançados de filtragem
- **Weaviate**: nativo de nuvem com forte capacidade de busca híbrida
- **pgvector**: extensão para PostgreSQL
- **Faiss**: pelo Meta para busca e agrupamento de vetores densos
- **Redis**: em memória
- **OpenSearch**: pesquisa de texto completo com similaridade semântica
- **LanceDB**: leve e facilidade de integração em pipelines




Diagrama da arquitetura do sistema



Docker

Plataforma de código aberto que automatiza a criação, implantação e execução de aplicações em contêineres

Container é uma unidade de software leve, autossuficiente e isolada que empacota o código de uma aplicação junto com todas as suas dependências



docker

Vercel

- Plataforma de computação em nuvem focada no desenvolvedor
- Foca em hospedar sites e aplicativos web
- Destaca-se na velocidade e integração nativa com o Next.js
- Características: foco no front-end, conexão com Git, e Ambiente Serverless
- Vantagens: implantação rápida, visualização de pull requests (cria links únicos de testes para cada alteração no código antes de ir para o ar), e domínios personalizados



FastAPI

- Framework web moderno, de alto desempenho e rápido para construir APIs



Uvicorn

- Servidor web ASGI (Asynchronous Server Gateway Interface)
- Altíssima performance para Python, ideal para frameworks assíncronos
- Projetado para lidar com conexões HTTP/1.1 e WebSockets



NGINX

- Software de servidor web de alto desempenho, código aberto e gratuito, amplamente utilizado como proxy reverso, balanceador de carga, cache HTTP e servidor de e-mail
- Arquitetura assíncrona orientada a eventos
- Lida com milhares de conexões simultâneas consumindo pouca memória



Kotlin

- Linguagem de programação moderna, concisa e de código aberto
- Permite criar aplicativos para Android
- Desenvolvida pela JetBrains
- Interoperável com Java
- Desenvolvimento Android



LangChain

- Framework open-source
- Simplifica a criação de aplicações com LLM
- Facilita conexão com fontes de dados externas, memória e ferramentas
- Encadeia funcionalidades



Referências

- <https://aws.amazon.com/what-is/retrieval-augmented-generation/>
- <https://www.hostinger.com/br/tutoriais/o-que-e-ollama>
- <https://triggo.ai/blog/o-que-e-retrieval-augmented-generation/>
- <https://pt.community.intersystems.com/post/modelos-llm-e-aplica%C3%A7%C3%B5es-rag-passo-passo-parte-ii-criando-o-contexto>
- <https://www.ibm.com/br-pt/think/topics/langchain>
- <https://ai.google.dev/gemma/docs/embeddinggemma?hl=pt-br>
- <https://ollama.com/library/embeddinggemma>
- <https://www.datacamp.com/pt/tutorial/chromadb-tutorial-step-by-step-guide>
- <https://www.instaclustr.com/education/vector-database/top-10-open-source-vector-databases/>
- <https://aws.amazon.com/pt/compare/the-difference-between-docker-images-and-containers/>
- <https://www.ibm.com/br-pt/think/topics/docker>
- <https://cloud.google.com/use-cases/langchain?hl=pt-BR>
- <https://www.f5.com/glossary/nginx>
- <https://kotlinlang.org/>
- <https://dev.to/sucodelarangela/como-colocar-um-projeto-no-ar-com-vercel-2m9d>